

Guide du projet

Analyse et optimisation marketing basée sur la segmentation client

Groupe : Toky, Miora, Manassé, Câline, Lalatiana, Chateau Brillant

Objet : comprendre ce que le sujet demande, qui fait quoi et dans quel ordre

Statut : document de travail interne – septembre 2026

1. Ce que le projet demande

Le professeur nous demande de **jouer le rôle de l'équipe marketing d'une entreprise** qui vend des vêtements et des accessoires, en magasin et en ligne. Cette entreprise dispose de données sur ses clients, ses produits, ses ventes et ses campagnes publicitaires. Notre mission est de répondre à une question centrale :

Comment mieux cibler chaque type de client pour vendre plus et dépenser le budget publicitaire plus intelligemment, en s'aidant de l'intelligence artificielle ?

Pour y répondre, le sujet découpe le travail en **9 modules (M1 à M9)** qui s'enchaînent : chaque module utilise les résultats du précédent. Ce qui sera évalué avant tout, c'est la **cohérence** : la stratégie finale doit découler logiquement de nos analyses, et pas seulement reposer sur des calculs justes.

Les 9 modules du sujet

Module	Thème	Données utilisées	Outils / techniques
M1	Enjeux stratégiques de la personnalisation	Aucune (théorique)	SWOT, 5P, parcours client
M2	Exploration des données	customers, sales, products	Python (pandas, matplotlib)
M3	Segmentation client	customers + sales (jointure)	K-means, PCA, t-SNE, clustering hiérarchique
M4	Profilage des segments	Résultats de M3	Analyse de profils, personas
M5	Performance des campagnes	marketing	CTR, taux de conversion, CPC, CPA, ROI
M6	Prédiction du churn ou de la CLV	sales, customers	Régression logistique, Random Forest, XGBoost
M7	Stratégie marketing digitale	Segments + KPIs des campagnes	Plan stratégique : canaux, contenu, budget
M8	Dashboard marketing	Toutes les données fusionnées	Streamlit
M9	Présentation finale et livrables	Synthèse du projet	Rapport, PowerPoint, oral

2. Les cinq grandes phases du projet

Les 9 modules se regroupent en cinq phases. Comprendre cet enchaînement permet à chacun de savoir à quoi sert son travail dans l'ensemble.

Phase 1 – Comprendre le contexte (M1)

Avant de toucher aux données, on réfléchit comme un stratège : pourquoi est-il important de personnaliser le marketing au lieu d'envoyer la même publicité à tout le monde ? On utilise trois outils classiques : la **SWOT** (forces, faiblesses, opportunités, menaces), les **5P** (produit, prix, place, promotion, personnes) et le **parcours client** (de la découverte de la marque jusqu'à l'achat puis la fidélité). Cette partie est purement théorique.

Phase 2 – Connaître les clients (M2, M3, M4)

M2 – Explorer les données. On ouvre les fichiers, on les nettoie et on fait des graphiques pour voir ce qu'ils racontent : âge des clients, qui dépense le plus, quels produits se vendent, par quel canal.

M3 – Segmenter. C'est le cœur du projet. On regroupe les clients qui se ressemblent (âge, montant dépensé, produits achetés) en quelques groupes appelés **segments**. Ce n'est pas nous qui faisons les groupes à la main : c'est un algorithme comme K-means. PCA et t-SNE servent à dessiner ces groupes sur un graphique.

M4 – Décrire chaque segment. On donne une identité à chaque groupe, par exemple « les jeunes acheteurs en ligne à petit budget ». Pour chacun, on crée un **persona** : un client imaginaire qui représente le groupe, avec un prénom, un âge, des habitudes et des besoins.

Phase 3 – Évaluer la publicité (M5)

L'entreprise a lancé 5 campagnes sur différents canaux (en ligne, en magasin, réseaux sociaux, email, TV). On mesure leur efficacité : combien de personnes ont vu la publicité, combien ont cliqué, combien ont acheté, combien a coûté chaque clic et chaque vente, et au final combien la campagne a rapporté par rapport à son coût (ROI). Le but est de savoir quel canal fonctionne le mieux.

Phase 4 – Prédire avec l'IA (M6)

On construit un modèle d'intelligence artificielle qui prédit l'avenir d'un client : risque-t-il d'arrêter d'acheter (**churn**) ? Combien va-t-il rapporter au total (**CLV**, valeur vie client) ? On teste plusieurs algorithmes et on garde le meilleur. En pratique, cela permet à l'entreprise de savoir quels clients retenir ou choyer en priorité.

Phase 5 – Décider et présenter (M7, M8, M9)

M7 – La stratégie. C'est l'aboutissement du projet. En combinant les segments et les résultats des campagnes, on propose un plan concret : pour chaque segment, quel canal utiliser, quel message ou quelle offre, et quelle part du budget. Exemple : « les jeunes, on les touche sur les réseaux sociaux avec des promotions, car c'est le canal le plus rentable pour eux ».

M8 – Le dashboard. Une application web interactive qui affiche les chiffres clés, les segments et les campagnes, avec des filtres. C'est l'outil que consulterait un directeur marketing.

M9 – La soutenance. On présente l'ensemble à l'oral comme si on défendait notre stratégie devant la direction : pitch, démonstration du dashboard et recommandations.

À retenir : M1 pose le décor ; M2 à M6 constituent l'analyse (ce qu'on apprend des données) ; M7 est la décision (ce qu'on recommande grâce à ces analyses) ; M8 et M9 sont la communication (comment on le montre).

3. Les livrables attendus

Le sujet exige six livrables. Le tableau indique de quels modules ils proviennent et qui en est responsable dans notre groupe.

Livable	Modules	Responsable
Segmentation client et profils détaillés	M3, M4	Miora
Analyse des campagnes et recommandations	M5, M7	Manassé (campagnes) et Lalatiana (stratégie)
Modèles IA de prédiction (churn, valeur client)	M6	Câline
Dashboard interactif	M8	Toky
Rapport final (Word ou PDF)	Tous	Chateau Brillant (assemblage), chacun rédige sa partie
Présentation orale (PowerPoint)	M9	Manassé (montage), chacun présente sa partie

4. Les données et leurs limites

Le professeur a fourni quatre fichiers CSV. Chacun ne contient que **5 lignes**.

Fichier	Contenu	Lignes	Colonnes
customers_data	Clients	5	Customer_ID, Name, Age, Gender, Location, Join_Date, Total_Spent
products_data	Produits	5	Product_ID, Product_Name, Category, Price, Brand
sales_data	Ventes	5	Sale_ID, Product_ID, Customer_ID, Date, Quantity, Sale_Price, Channel
marketing_data	Campagnes	5	Campaign_ID, Channel, Start_Date, End_Date, Budget, Impressions, Clicks, Conversions

Problème principal : le volume

Les méthodes demandées (K-means, Random Forest, XGBoost) apprennent à partir de nombreux exemples. Avec 5 clients, elles ne peuvent rien apprendre de fiable : chaque segment ne contiendrait qu'un ou deux clients, et il ne resterait presque rien pour tester un modèle de prédiction. C'est comme faire un sondage national en interrogeant 5 personnes.

Solution retenue : générer un jeu de données étendu (environ 500 à 1000 clients et plusieurs milliers de ventes) avec exactement les mêmes colonnes. L'analyse est faite sur les données d'origine pour montrer notre compréhension, puis sur le jeu étendu pour que les méthodes d'IA fonctionnent réellement. La méthode de génération doit être expliquée dans le rapport.

Autres incohérences relevées

N°	Problème	Constat	Solution proposée
1	Sale_Price non homogène	Vente 1 : $2 \times 25 = 50$ (prix total). Vente 3 : $3 \times 30 = 30$ (prix unitaire ou erreur).	Fixer une règle (Sale_Price = prix total) et corriger.
2	Total_Spent $\neq$ ventes	Alice : 500 dans customers_data, mais 80 dans sales_data.	Considérer Total_Spent comme un cumul historique et le préciser.
3	Client sans achat	Eva (client 2005) n'apparaît dans aucune vente.	La conserver : elle illustre un client inactif, utile pour le churn.
4	Pas de chiffre d'affaires	marketing_data ne donne pas l'argent rapporté : le ROI n'est pas calculable directement.	Hypothèse : revenu = conversions $\times$ panier moyen des ventes.
5	Canaux différents	Ventes : Online, In-Store. Campagnes : aussi Social, Email, TV.	Analyser les campagnes par canal sans lien direct vente-campagne, et le signaler.
6	Pas de variable churn	Aucun fichier n'indique si un client est parti.	Définir une règle, par exemple : aucun achat depuis 90 jours.

Ces limites doivent figurer dans le rapport, dans une section « Qualité des données et limites ». Elles sont probablement voulues par le professeur et permettent de montrer notre esprit critique.

5. Répartition des tâches

Le groupe compte six membres ; chacun a sa propre partie. La répartition suit les modules du sujet ; la soutenance (M9) et la rédaction concernent tout le monde.

Membre	Modules	Rôle
Toky	M2 + M8	Préparation des données et dashboard
Miora	M3 + M4	Segmentation et personas
Manassé	M5 + PowerPoint	Performance des campagnes et présentation
Câline	M6	Modèles de prédiction
Lalatiana	M7	Stratégie marketing digitale et budget
Chateau Brillant	M1 + rapport	Cadre stratégique et rapport final
Tout le monde	M9	Rédaction de sa partie et présentation orale

Toky – M2 Exploration des données et M8 Dashboard

Préparer des données propres et fiables pour tout le groupe, puis construire l'outil qui présente l'ensemble des résultats. Le travail sur M2 est le plus urgent : Miora et Câline en dépendent.

Tâche	Ce qu'il faut faire
Nettoyer les 4 fichiers CSV	Vérifier les types (dates, nombres), les doublons et les valeurs manquantes.
Corriger les incohérences	Appliquer les règles décidées pour Sale_Price, Total_Spent et le client sans achat (section 4).
Générer le jeu de données étendu	Créer environ 500 à 1000 clients et plusieurs milliers de ventes avec les mêmes colonnes ; documenter la méthode.
Fusionner les fichiers	Joindre ventes, clients et produits dans un seul fichier de travail.
Faire les graphiques d'exploration	Âge, dépenses, ventes par catégorie et par canal, évolution dans le temps ; commenter chaque graphique.
Livrer le fichier propre	Déposer le fichier fusionné sur le dépôt commun : c'est la seule version utilisée par le groupe.
Créer le dashboard Streamlit	Application avec filtres et au minimum trois vues : ventes, segments, campagnes.
Intégrer les résultats du groupe	Brancher les fichiers CSV livrés par Miora, Manassé et Câline.
Préparer la démo	Scénario de démonstration de quelques minutes pour la soutenance.

Reçoit : les résultats en CSV de Miora (segments), Manassé (KPIs) et Câline (prédictions).

Livre : le fichier fusionné à tout le groupe, puis le dashboard final.

Miora – M3 Segmentation et M4 Profilage

Découvrir les groupes de clients qui se ressemblent et leur donner une identité. Ses segments sont la base de la stratégie finale (M7).

Tâche	Ce qu'il faut faire
Préparer les variables	Pour chaque client : âge, montant dépensé, nombre d'achats, catégories achetées, canal préféré, indicateurs RFM. Normaliser les valeurs.
Faire le K-means	Regrouper automatiquement les clients en segments.
Choisir le nombre de segments	Méthode du coude et score de silhouette ; justifier le choix.
Faire la classification hiérarchique	Dendrogramme pour comparer avec le résultat du K-means.
Visualiser avec PCA et t-SNE	Représenter les segments sur un graphique en deux dimensions.
Décrire chaque segment	Âge moyen, panier moyen, produits et canal préférés ; donner un nom à chaque segment.
Créer les personas	Une fiche par segment : prénom fictif, âge, habitudes, besoins, freins, canaux.
Livrer les segments	Fichier CSV : Customer_ID, numéro et nom du segment.

Reçoit : le fichier fusionné de Toky.

Livre : les segments en CSV à Toky ; les profils et personas à Lalatiana.

Manassé – M5 Performance des campagnes et PowerPoint

Mesurer ce qu'ont rapporté les campagnes et identifier les canaux les plus rentables, puis monter la présentation finale. Il peut commencer immédiatement : M5 n'utilise que marketing_data.

Tâche	Ce qu'il faut faire
Calculer les KPIs	Pour chaque campagne : CTR (clics / impressions), taux de conversion (conversions / clics), CPC (budget / clics), CPA (budget / conversions) et ROI.
Poser l'hypothèse du ROI	Estimer le revenu : conversions × panier moyen ; l'écrire clairement.
Comparer campagnes et canaux	Classer les canaux du plus rentable au moins rentable.
Faire les graphiques des KPIs	Visualiser les résultats par canal.
Livrer les KPIs	Fichier CSV des KPIs par campagne pour le dashboard et pour la stratégie.
Monter le PowerPoint	Assembler les slides de chacun dans une présentation homogène.

Reçoit : les slides de chaque membre.

Livre : les KPIs en CSV à Toky et à Lalatiana ; le PowerPoint final.

Câline – M6 Prédiction du churn et de la CLV

Construire un modèle d'intelligence artificielle qui prédit le comportement futur des clients : risque de départ (churn) et/ou valeur (CLV).

Tâche	Ce qu'il faut faire
Définir la règle du churn	Par exemple : un client sans achat depuis 90 jours est considéré comme parti ; justifier le seuil.
Calculer la CLV et le RFM	Récence, fréquence, montant ; estimation de la valeur de chaque client.
Préparer les données	Séparer en jeu d'entraînement et jeu de test.
Entraîner la régression logistique	Modèle de référence simple.
Entraîner le Random Forest	Modèle plus puissant, basé sur de nombreux arbres de décision.
Entraîner le XGBoost	Modèle souvent le plus performant.
Comparer les modèles	Accuracy, F1, AUC (churn) ou MAE, RMSE (CLV) ; retenir le meilleur.
Interpréter les résultats	Variables les plus importantes ; clients à risque ou à forte valeur.
Livrer les prédictions	Fichier CSV : Customer_ID, probabilité de churn et/ou CLV.

Reçoit : le fichier fusionné de Toky.

Livre : les prédictions en CSV à Toky ; les conclusions à Lalatiana.

Lalatiana – M7 Stratégie marketing digitale

Transformer toutes les analyses du groupe en un plan d'action concret : quel segment toucher, sur quel canal, avec quel message et quel budget. C'est l'aboutissement du projet.

Tâche	Ce qu'il faut faire
Rédiger la stratégie par segment	Pour chaque segment de Miora : canal, message ou contenu, offre ; en s'appuyant sur les KPIs de Manassé et les prédictions de Câline.
Proposer la répartition du budget	Quelle part du budget sur quel canal, justifiée par la rentabilité mesurée en M5.
Prévoir les actions de fidélisation	Actions ciblées sur les clients à risque de churn ou à forte valeur identifiés en M6.
Expliquer le rôle de l'IA	Scoring des clients, recommandation, automatisation des actions.
Définir le calendrier des actions	Ordre et durée des actions prévues dans le plan.
Définir les KPIs de suivi	Indicateurs qui permettront de mesurer le succès du plan.

Reçoit : les personas (Miora), les KPIs (Manassé) et les prédictions (Câline).

Livre : la stratégie complète à Chateau Brillant pour le rapport.

Chateau Brillant – M1 Enjeux stratégiques et rapport final

Poser le cadre stratégique du projet, puis assembler le rapport final à partir des parties de chacun. Il peut commencer immédiatement avec M1.

Tâche	Ce qu'il faut faire
Faire la SWOT	Forces, faiblesses, opportunités et menaces de l'entreprise.
Faire les 5P	Produit, prix, place, promotion, personnes.
Faire le parcours client	Découverte, considération, achat, fidélisation ; enjeux de personnalisation à chaque étape.
Rédiger l'introduction et la conclusion	Présenter le contexte et la problématique ; résumer les résultats et les recommandations.
Rédiger la section sur les données	Section « Qualité des données et limites » à partir des constats de la section 4.
Assembler le rapport final	Réunir les parties de chacun et harmoniser le style et la mise en page.
Relire le rapport	Vérifier la cohérence entre les parties et que la stratégie découle bien des analyses.

Reçoit : la stratégie (Lalatiana) et les parties du rapport de chacun.

Livre : le rapport final.

Tout le monde – M9 Présentation finale

Tâche	Ce qu'il faut faire
Rédiger sa partie du rapport	Méthode, résultats et interprétation de son module ; envoi à Chateau Brillant.
Préparer ses slides	Deux à quatre slides pour sa partie ; envoi à Manassé.
Présenter à l'oral	Chacun présente sa partie ; Toky fait la démonstration du dashboard.

6. Ordre de travail

Certaines tâches dépendent d'autres. Respecter cet ordre évite que des membres restent bloqués.

Chaîne de dépendances

M2 → M3 → M4 → M7

M2 → M6 → M7

M5 → M7

Tous les résultats → M8 → M9

Les quatre étapes

Étape	Qui	Quoi	Condition de démarrage
A. Démarrage	Tout le monde	Toky : M2 en priorité. Manassé : M5. Chateau Brillant : M1. Lalatiana prépare la structure du plan stratégique. Miora et Câline préparent leur code sur les 5 lignes d'origine.	Immédiate
B. Analyses	Miora, Câline, Toky	M3 puis M4 (Miora), M6 (Câline). Toky prépare la structure du dashboard.	Fichier fusionné et étendu livré par Toky
C. Stratégie et intégration	Lalatiana, Toky	M7 (stratégie et budget). Toky intègre les CSV de résultats dans le dashboard.	Segments, KPIs et prédictions livrés
D. Finalisation	Tout le monde	Rédaction des parties, assemblage du rapport, montage du PowerPoint, répétition de l'oral.	Dashboard et stratégie terminés